

Российский университет транспорта РУТ (МИИТ)
Высшая инженерная школа (ВИШ)

Анализ больших текстовых данных и текстовый поиск

Лекция 13

08 декабря 2025

Text Summarization

Автоматическая суммаризация (резюмирование) текста — это задача генерации краткого представления одного или нескольких документов с сохранением их ключевого смыслового содержания

Вход:


Один документ или набор связанных документов

Выход:

Короткий связный текст, отражающий основную информацию исходных данных

Ключевая цель:

Сократить объём информации без потери смыслового ядра



Text Summarization

Причины появления

- **Рост объёма текстовых данных:** новости, отчёты, юридические документы, научные статьи, логи, переписка. Человек физически не успевает всё читать полностью
- **Экономия времени:** быстрое понимание сути без полного чтения. Поддержка принятия решений
- **Автоматизация аналитики:** предварительная обработка документов, подготовка обзоров и дайджестов
- **Уменьшение когнитивной нагрузки:** фильтрация второстепенной информации, фокус на главном
- **Интеграция в ИИ-системы:** summarization как промежуточный этап в RAG, поиске, аналитике, агентных системах

Text Summarization

Применение

- **Новости и медиа:** автоматические дайджесты, сводки по событиям, объединение нескольких источников
- **Юридические документы:** суммаризация договоров, выделение ключевых условий, анализ судебных решений
- **Отчёты и бизнес-аналитика:** годовые и квартальные отчёты, сводки по результатам деятельности, аналитические записки для руководства
- **Научные статьи:** автоматические аннотации, быстрое ознакомление с тематикой, поддержка систем научного поиска
- **RAG-системы:** сжатие документов перед индексацией, суммаризация найденных фрагментов перед подачей в LLM, иерархическая суммаризация длинных источников

Text Summarization

Отличие суммаризации от смежных задач seq2seq

- **Суммаризация**

Цель: сжать информацию. Сохраняется общий смысл. Объём существенно уменьшается

- **Перефразирование**

Цель: изменить формулировку. Смысл сохраняется полностью. Объём обычно не меняется

- **Упрощение текста**

Цель: сделать текст проще для восприятия. Может сохраняться почти весь объём.
Меняется уровень сложности языка

- **Перевод**

Цель: смена языка. Объём и смысл сохраняются. Нет задачи сжатия

Text Summarization

Почему задача нетривиальна

- Не все важные факты выражены явно
- Разный уровень значимости информации
- Необходимо сохранять причинно-следственные связи
- Высокий риск потери деталей
- Возможны генеративные искажения в нейросетевых моделях

Text Summarization

Основные требования к качеству суммаризации

- **Информативность:** в резюме должны присутствовать все ключевые факты, не допускается потеря критически важной информации
- **Связность:** логическая последовательность мыслей, отсутствие обрывочных фраз, корректные ссылки
- **Отсутствие искажений:** факты не должны изменяться, причинно-следственные связи должны сохраняться, а числа, даты, имена должны быть корректны
- **Компактность:** минимально возможный объём при сохранении смысла, отсутствие повторов и второстепенных деталей

Классификация подходов

По типу генерации

- Extractive summarization. Выбор предложений из исходного текста
- Abstractive summarization. Генерация нового текста




По количеству документов

- Single-document summarization
- Multi-document summarization

По цели

- Общие аннотации (Generic summarization)
- Суммаризация по запросу (Query-focused summarization)
- Обновляющая суммаризация (Update summarization)



Классические extractive методы

Document

London Welsh have announced a contract extension for their former England international back Ollly Barkley. The 33-year-old joined the Exiles last year, having previously played for Bath, Gloucester, Racing Metro, Grenoble and the Scarlets. He won 23 Test caps, the last of which was against New Zealand in 2008. Ollly Barkley has extended his stay at London Welsh after signing a new contract at the relegated-club. Welsh are set to return to the Championship next season after finishing bottom of the Aviva Premiership. 'It has not been an easy year, but I am committed to seeing my journey with London Welsh through,' Barkley said. 'I am really looking forward to working with our new team and the reinvigorated coaching regime, which is being put together, to put this season behind us and lay a strong foundation for promotion back to the Premiership for the 2016-17 season.' The fly half featured 23 times for England and previously played for Bath, Gloucester and Racing Metro.

Summary ($top_k = 3$)

London Welsh have announced a contract extension for their former England international back Ollly Barkley. Welsh are set to return to the Championship next season after finishing bottom of the Aviva Premiership. 'The fly half featured 23 times for England and previously played for Bath, Gloucester and Racing Metro.

Идея extractive-подхода: резюме формируется путём выбора наиболее важных предложений из исходного текста без их переформулирования

Общая схема

- Разбиение текста на предложения
- Оценка важности каждого предложения
- Отбор топ-k предложений
- Формирование резюме из выбранных фрагментов

Ключевые особенности

- Отсутствие генерации нового текста
- Минимальный риск фактических искажений

Классические extractive методы

Частотные методы. Общая идея

Основная гипотеза:

Чем чаще термин встречается в документе, тем он важнее

Предложения с важными терминами считаются более информативными

Базовые шаги:

- Токенизация
- Удаление стоп-слов
- Подсчёт частот
- Агрегация весов на уровне предложений

TF-IDF в суммаризации:

Показывает, насколько часто слово встречается в документе. Учитывает редкость слова в корпусе.

Вес предложения — сумма TF-IDF всех его слов, нормализованная по длине предложения

Классические extractive методы

Суммаризация по весу предложений

Алгоритм:

- Для каждого предложения вычисляется числовой скор
- Предложения ранжируются
- Отбираются предложения с максимальным скором
- Сохраняется исходный порядок для связности

Плюсы метода:

- Простота реализации
- Высокая скорость
- Не требует обучения

Классические extractive методы

Графовые методы

Представление текста:

Каждое предложение это вершина графа

Рёбра отражают семантическое сходство между предложениями


Цель:

Найти наиболее центральные предложения в графе

Основная идея:

Важное предложение — это то, которое связано с большим количеством предложений

Примеры: TextRank, LexRank



Классические extractive методы

Линейные оптимизационные модели

У нас есть много предложений. Надо выбрать несколько штук, чтобы:

- они были максимально полезными
- но не превысили заданную длину суммаризации

У каждого предложения i есть:

- вес w_i — насколько оно важное. Он берётся из TF-IDF, TextRank или любой другой модели
- длина l_i — количество слов или символов

Мы вводим переменную:

$x_i = 1$, если предложение выбрано

$x_i = 0$, если не выбрано

Классические extractive методы

Линейные оптимизационные модели

Тогда задача:

$$\max_{x_1, \dots, x_n} \sum_{i=1}^n w_i x_i$$

При условиях:

$$\sum_{i=1}^n l_i x_i \leq L \quad x_i \in \{0, 1\} \quad i = 1, \dots, n$$

L — максимально допустимая длина резюме

Классические extractive методы

Преимущества классических extractive методов

- Простота реализации
- Низкие вычислительные затраты
- Не требуют обучающих выборок
- Полная интерпретируемость
- Высокая фактическая точность
- Практически отсутствуют галлюцинации


Особенно хорошо подходят для:

- Юридических и технических документов
- Предварительного сжатия в RAG
- Систем с жёсткими требованиями к фактам

Классические extractive методы

Недостатки классических extractive методов

- Плохая связность итогового текста
- Повторы информации
- Полное копирование формулировок
- Отсутствие абстрагирования
- Слабая адаптация под цель пользователя
- Плохая работа с длинными сложными документами



Нейросетевые extractive методы

Общая идея

Каждому предложению присваивается оценка важности с помощью нейросети, после чего выбираются предложения с максимальным скором

Отличие от классических методов:

- Важность определяется не частотами слов
- Используется контекст
- Учитывается семантика предложения

Архитектуры:

- LSTM-based модели
- CNN + attention
- BERT-based модели

Нейросетевые extractive методы

Общая схема работы

- Документ разбивается на предложения
- Каждое предложение кодируется в вектор
- Нейросеть выдаёт скор важности
- Предложения ранжируются
- Выбираются топ-k предложений
- Формируется extractive-резюме

Нейросетевые extractive методы

1. LSTM-based sentence scoring


Идея

- Документ представляется как последовательность предложений
- Каждое предложение кодируется в вектор признаков
- Векторы подаются в LSTM по порядку следования в тексте
- LSTM формирует контекстные представления с учётом соседних предложений

Как считается скор

Каждое предложение кодируется скрытым состоянием LSTM с учётом соседнего контекста. Это состояние проходит через линейный слой и сигмоиду, в результате чего получается вероятность включения предложения в резюме.

Тем самым задача формулируется как бинарная классификация предложений.



Нейросетевые extractive методы

LSTM-based sentence scoring

Плюсы

- Учитывается порядок предложений
- Моделируется локальный контекст
- Простая и понятная архитектура

Минусы


- Последовательная обработка
- Плохо масштабируется на длинные документы
- Дальние зависимости затухают
- Медленный инференс по сравнению с трансформерами

Нейросетевые extractive методы

2. CNN + attention для оценки важности

Идея

- Предложение представляется как последовательность эмбеддингов слов
- Свёрточные фильтры выделяют локальные шаблоны слов
- Attention взвешивает вклад каждого слова
- Получается итоговый вектор предложения
- По нему через линейный слой считается скор важности



Нейросетевые extractive методы

CNN + attention для оценки важности

Преимущества

- Параллельная обработка слов
- Устойчива к шуму
- Быстрее LSTM

Ограничения

- Контекст за пределами одного предложения учитывается слабо
- Нет глобального понимания документа
- Качество сильно зависит от attention-механизма
- Уступает трансформерам по качеству на длинных текстах

Нейросетевые extractive методы

3. BERT-based extractive модели


Общая идея

- Документ подаётся целиком в BERT
- На уровне предложений берутся эмбединги
- Для каждого предложения считается скор включения в резюме

Преимущество

- Глубокое контекстное представление
- Учитываются дальние зависимости
- Лучше работает на сложных текстах


Transformer



Encoder

Decoder

BERT*



Encoder-only

Нейросетевые extractive методы

Преимущества нейросетевых extractive моделей

- Учитывают смысл, а не только частоты
- Учитывают контекст документа
- Работают устойчиво на сложных текстах
- Сильно превосходят TF-IDF и TextRank

Недостатки

- Требуют размеченных данных
- Риск переобучения под конкретный набор документов
- Всё ещё копируют исходные формулировки
- Не умеют абстрагировать
- Ограничены длиной контекста модели


Abstractive summarization

Abstractive-суммаризация формирует новый текст, который передаёт смысл исходного документа, но не обязан дословно повторять его фразы

Модель:

- анализирует содержание
- переосмысливает информацию
- генерирует связное краткое описание

В отличие от extractive-подходов, здесь происходит **реальная генерация**, а не выбор готовых предложений



Abstractive summarization

Проблема копирования и потери фактов

Abstractive-модели сталкиваются с двумя фундаментальными проблемами:

1. Потеря фактов

- пропуск важных деталей
- искажение чисел, дат, имён
- нарушение причинно-следственных связей

2. Неконтролируемое копирование


- модель начинает дословно переносить фрагменты текста
- абстрагирование фактически пропадает

Abstractive summarization

Encoder–Decoder архитектуры

Базовая архитектура abstractive-суммаризации это модель типа **encoder–decoder**

- **Encoder** принимает исходный текст, преобразует его в последовательность скрытых векторов, кодирует смысл входного документа
- **Decoder** пошагово генерирует токены резюме, на каждом шаге опирается на выходы encoder, формирует связный текст



Abstractive summarization

Attention-механизм

Attention позволяет декодеру динамически выбирать, на какие части входного текста опираться при генерации каждого слова.

На каждом шаге генерации модель:

- оценивает, какие фрагменты входного текста наиболее релевантны текущему моменту
- присваивает им веса важности
- вычисляет общий контекст как взвешенную сумму всех векторов фрагментов
- использует этот контекст при предсказании следующего токена

Назначение attention

- фокусировка на релевантных фрагментах
- повышение качества длинных резюме

Abstractive summarization

Coverage-механизм

Coverage-механизм вводится для контроля того, какие части входного текста уже были использованы вниманием

- накапливает сумму прошлых attention-весов
- штрафует модель за повторное внимание к тем же фрагментам
- снижает количество повторов в генерации

Эффект

- уменьшается дублирование фраз
- повышается полнота резюме
- улучшается структура текста

Abstractive summarization

Pointer–Generator Networks

Pointer–Generator Networks объединяют генерацию новых слов и копирование слов прямо из исходного текста

На каждом шаге модель решает:

- с какой вероятностью сгенерировать новое слово
- с какой вероятностью скопировать слово из входа

Это позволяет:

- сохранять имена, числа, термины
- снижать риск фактических ошибок
- сочетать абстрагирование и точное копирование

Abstractive summarization

Типичный abstractive-пайплайн

- encoder–decoder архитектура
- attention для фокусировки
- coverage для контроля повторов
- pointer–generator для точного копирования

В совокупности эти механизмы делают возможным:

- связную генерацию
- сохранение фактов
- контролируемое сжатие текста

Abstractive summarization

Иерархическое суммаризация длинных документов

Применяется, когда документ не помещается в контекстное окно модели.

Типичный пайплайн:

- разбиение документа на чанки
- суммаризация каждого чанка
- суммаризация полученных промежуточных резюме
- при необходимости несколько уровней иерархии

Преимущества:

- Обработка документов любого объёма
- Контролируемый уровень сжатия
- Масштабируемость

Недостаток: накопление ошибок между уровнями

Abstractive summarization на базе LLM

Summarization на базе LLM

Большие языковые модели выполняют суммаризацию как универсальную задачу генерации текста по инструкции без специального обучения под конкретный датасет

Ключевые особенности:

- отсутствие жёсткой архитектурной привязки
- работа через текстовую инструкцию
- высокая связность и естественность языка
- способность учитывать сложный контекст и цель пользователя

Abstractive summarization на базе LLM

Zero-shot суммаризация

Zero-shot означает, что модель не видит ни одного примера суммаризации, а получает только инструкцию.

Пример формулировки задачи: «Сделай краткое содержание следующего текста...»

Особенности zero-shot:

- не требует примеров
- легко масштабируется
- качество зависит от точности формулировки запроса
- нестабильно для узкоспециализированных областей

Используется, когда:

- нет обучающих данных
- требуется быстрое прототипирование

Abstractive summarization на базе LLM

Few-shot суммаризация

Few-shot означает, что в промпт добавляются несколько примеров пар «текст – резюме»

Что это даёт:

- задание нужного стиля
- контроль длины и структуры
- повышение стабильности результата
- частичная адаптация под специфику области без обучения

Ограничения:

- съедает часть контекстного окна
- качество сильно зависит от подобранных примеров

Метрики оценки качества суммаризации

Качество резюме оценивается двумя группами методов:

- автоматические метрики
- человеческая экспертная оценка

Автоматические метрики дают быстрый численный показатель, а человеческая оценка отражает реальное качество восприятия текста.



Метрики оценки качества суммаризации

Автоматические метрики

Общая идея:

Автоматические метрики сравнивают сгенерированное резюме с эталонным человеческим резюме

Сравнение строится:

- по совпадению слов
- по совпадению фраз
- по семантической близости

Основная проблема: высокое совпадение слов не всегда означает высокое качество смысла

Примеры: ROUGE-1, ROUGE-2, ROUGE-L, BLEU, BERTScore, BLEURT, COMET

Метрики оценки качества суммаризации

Человеческая оценка качества

Человеческая оценка проводится экспертами и отражает реальное качество суммаризации при практическом использовании

Обычно применяется для валидации моделей, для финальной проверки в продакшене, при сравнении разных архитектур

- Полнота — отражены ли все ключевые идеи исходного текста
- Точность — нет ли фактических ошибок и искажённых данных
- Связность — логичность и плавность изложения
- Отсутствие искажений — нет ли вымышленных фактов и ложных выводов