

## Лабораторная работа 1

**Цель:** освоить основные инструменты для предварительной обработки и первичного анализа текстовых данных

### Задания:

#### 1) Настройка виртуальной среды разработки conda

- a. Если на вашем ноутбуке уже установлена Miniconda или альтернативный инструмент создания и настройки виртуальной среды разработки Python (Anaconda, virtualenv, venv, poetry, uv,...), в котором можно открывать, редактировать и запускать код из файла jupyter notebook, можно переходить сразу к пункту 2.
- b. Скачать и установить Miniconda, следуя инструкции "Quickstart install instructions" для вашей системы на официальном сайте <https://www.anaconda.com/docs/getting-started/miniconda/install#quickstart-install-instructions>  
Выбор обусловлен тем, что Anaconda является стандартным и простым в использовании инструментом создания виртуальной среды для проектов в области анализа данных. Но вы можете использовать и другие инструменты на ваше усмотрение.
- c. Найти в списке программ и запустить Anaconda Prompt (на Mac OS обычный терминал)
- d. После успешной установки в терминале создать и активировать среду с tensorflow для CPU, загрузить в неё нужные библиотеки:

```
conda create -n lab_env tensorflow
conda activate lab_env
conda install numpy pandas matplotlib seaborn scikit-learn
pip install pymorphy3 nltk
conda install jupyter
```

#### 2) Выполните задания в ноутбуке Семинар\_2\_Лабораторная.ipynb, ориентируясь на Ваш вариант (смотрите таблицу в конце файла). Данные для обработки находятся в файле Lesson\_1\_user\_requests.csv.

У каждого студента свой вариант, номер варианта совпадает с вашим номером в списке группы. Вариант определяет:

- Целевую переменную, которую модель должна будет предсказывать: «sphera» или «categoriya»

- Атрибут `num_words` класса `Tokenizer()`, определяющий количество самых часто встречающихся слов из сформированного словаря, которые будут использоваться при токенизации текста

- Какую технику нормализации необходимо применить: лемматизация или стемминг

- Необходимо ли исключать некоторые классы из процесса обучения

- Необходимо ли задавать дополнительные условия при разбиении данных на тренировочную и тестовую выборки

- Значение параметра «mode» функции `texts_to_matrix()` для векторизации текста

3) Покажите полностью выполненный ноутбук с заполненными пропусками и ответьте на вопросы. После этого мы отметим, что вы сдали лабораторную работу.

| Вариант |                                    | Цель       | num_words | Лемматизация/<br>Стемминг | Дополнительная работа над<br>целевой переменной     | Дополнительная работа над<br>разбиением на тренировочную и<br>тестовую выборки           | mode в<br>texts_to_matrix() |
|---------|------------------------------------|------------|-----------|---------------------------|-----------------------------------------------------|------------------------------------------------------------------------------------------|-----------------------------|
| 1       | Аржанников Семён Евгеньевич        | sphera     | 60000     | Лемматизация              | исключить классы, в которых<br>меньше 200 обращений | нет                                                                                      | binary                      |
| 2       | Артемова Анастасия Дмитриева       | categoriya | 10000     | Лемматизация              | исключить классы, в которых<br>меньше 300 обращений | нет                                                                                      | count                       |
| 3       | Белов Александр Сергеевич          | sphera     | 1000000   | Лемматизация              | нет                                                 | обеспечить пребывание всех классов в<br>тестовой выборке                                 | tfidf                       |
| 4       | Герасимова Полина Андреевна        | categoriya | 30000     | Лемматизация              | нет                                                 | обеспечить сохранение распределения<br>по классам в тренировочной и тестовой<br>выборках | freq                        |
| 5       | Гурнов Кирилл Максимович           | sphera     | 1000      | Лемматизация              | исключить классы, в которых<br>меньше 500 обращений | нет                                                                                      | binary                      |
| 6       | Доронин Егор Михайлович            | categoriya | 80000     | Лемматизация              | нет                                                 | обеспечить пребывание всех классов в<br>тестовой выборке                                 | count                       |
| 7       | Егоров Тимофей Павлович            | sphera     | 90000     | Лемматизация              | нет                                                 | обеспечить пребывание всех классов в<br>тестовой выборке                                 | tfidf                       |
| 8       | Жарков Егор Степанович             | categoriya | 100000    | Лемматизация              | нет                                                 | обеспечить сохранение распределения<br>по классам в тренировочной и тестовой<br>выборках | freq                        |
| 9       | Коробкина Любовь Юрьевна           | sphera     | 110000    | Лемматизация              | нет                                                 | Обеспечить перемешивание данных при<br>формировании выборок                              | binary                      |
| 10      | Кратюк Илья Витальевич             | categoriya | 20000     | Лемматизация              | нет                                                 | обеспечить пребывание всех классов в<br>тестовой выборке                                 | count                       |
| 11      | Кузовкова Анастасия Евгеньевна     | sphera     | 30000     | Лемматизация              | нет                                                 | Обеспечить перемешивание данных при<br>формировании выборок                              | tfidf                       |
| 12      | Лалетин Павел Дмитриевич           | categoriya | 60000     | Лемматизация              | исключить классы, в которых<br>меньше 200 обращений | нет                                                                                      | freq                        |
| 13      | Ласточкина София Валерьевна        | sphera     | 10000     | Лемматизация              | исключить классы, в которых<br>меньше 300 обращений | нет                                                                                      | binary                      |
| 14      | Мельников Иван Александрович       | categoriya | 1000000   | Стемминг                  | нет                                                 | обеспечить пребывание всех классов в<br>тестовой выборке                                 | count                       |
| 15      | Михальков Михаил Алексеевич        | sphera     | 30000     | Стемминг                  | нет                                                 | обеспечить сохранение распределения<br>по классам в тренировочной и тестовой<br>выборках | tfidf                       |
| 16      | Мукайлов Мирзекерим<br>Нариманович | categoriya | 1000      | Стемминг                  | исключить классы, в которых<br>меньше 500 обращений | нет                                                                                      | freq                        |
| 17      | Панкратов Мирон Георгиевич         | categoriya | 80000     | Стемминг                  | нет                                                 | Обеспечить перемешивание данных при<br>формировании выборок                              | binary                      |

|    |                              |            |        |          |                                                  |                                                                                    |        |
|----|------------------------------|------------|--------|----------|--------------------------------------------------|------------------------------------------------------------------------------------|--------|
| 18 | Петрова Екатерина Сергеевна  | sphera     | 90000  | Стемминг | нет                                              | обеспечить пребывание всех классов в тестовой выборке                              | count  |
| 19 | Поздняков Артем Евгеньевич   | categoriya | 100000 | Стемминг | нет                                              | обеспечить сохранение распределения по классам в тренировочной и тестовой выборках | tfidf  |
| 20 | Полунин Леонид Дмитриевич    | categoriya | 110000 | Стемминг | нет                                              | Обеспечить перемешивание данных при формировании выборок                           | freq   |
| 21 | Секинаев Данил Аланович      | sphera     | 20000  | Стемминг | нет                                              | обеспечить пребывание всех классов в тестовой выборке                              | binary |
| 22 | Сорокина Юлия Александровна  | categoriya | 30000  | Стемминг | нет                                              | Обеспечить перемешивание данных при формировании выборок                           | count  |
| 23 | Худжаилов Умар Назирджонович | sphera     | 60000  | Стемминг | исключить классы, в которых меньше 200 обращений | нет                                                                                | tfidf  |
| 24 | Чепулянис Егор Алексеевич    | categoriya | 10000  | Стемминг | исключить классы, в которых меньше 300 обращений | нет                                                                                | freq   |