

Курсовая работа

Цель курсовой работы – анализ сообщений в социальных сетях.

Навыки:

- 1) Парсинг данных из групп в социальных сетях
- 2) Практическое применение алгоритмов анализа текстовых данных
- 3) Составление отчёта о проделанной работе
- 4) Защита работы

Исходная информация для анализа должна быть собрана из открытых источников (telegram, VK, альтернатива по согласованию).

Индивидуальные варианты приведены в файле “**Варианты_3курс.xlsx**”

Вариант определяет:

- 1) Темы для выбора каналов/групп.
- 2) Источник данных (Telegram или VK)
- 3) Задача для анализа

Парсинг данных:

- Telegram: библиотека Telethon (pip install Telethon)

Примеры возможных каналов в Telegram (в зависимости от варианта):

@rut_live, @avtodorgk, @favt_ru, @rosavtodor, @morflot_gov,
@Mintrans_Russia, @telerzd, @DtRoad, @aviatorshina, ...

- VK: библиотека vk_api (pip install vk_api)

Примеры возможных групп VK (в зависимости от варианта): rzd_official,
aeroflot, passtransportspb, ...

Если для вашего варианта возникают проблемы с поиском подходящих источников, можно поменять тему в индивидуальном порядке.

Для автоматизированного парсинга необходимо получить данные для аутентификации разработчика. Алгоритм действий будет указан в отдельной инструкции.

Для парсинга сообщений из групп Telegram вы можете воспользоваться скриптом **parser_telegram.py**

В ноутбуке **course_project.ipynb** парсинг из VK и примеры работы с полученными данными из VK и Telegram.

Вы можете написать свой парсер, если вам не нравится предоставленный, или усовершенствовать имеющийся.

Критерии оценивания:

Для успешной сдачи работы на отлично должны быть выполнены следующие условия:

- Письменный отчёт: введение (постановка задачи, цель работы, выбранный метод), теоретическая часть, сбор и подготовка данных (какие группы/каналы, метод сбора данных, предобработка), методика, результаты, выводы, список использованных источников информации. Количество страниц не фиксировано, но хороший отчёт с графиками обычно занимает около 10 страниц или чуть больше.
- Выбор источников, соответствующих теме вашего варианта (объём данных для работы: не менее 3000 сообщений/постов/комментариев всего)
- Полноценная предварительная обработка текстовых данных
- Описательная статистика (построить несколько графиков для визуализации исходных данных и результатов анализа, это может быть, например, распределение длин сообщений, облака слов, распределение сообщений по классам и другие, в зависимости от задачи)
- Обзор существующих методов и подбор наиболее подходящего метода для решения задачи
- Корректность реализации выбранного метода
- Интерпретация результатов (почему получились именно такие результаты, сформулируйте основные выводы)

Оценка может быть снижена за:

- Использование источников, не соответствующих варианту (без предварительного согласования)
- Решение задачи, не соответствующей варианту (без предварительного согласования)
- Плохо написанный отчёт (не хватает каких-то разделов, или их содержание не соответствует теме работы, или выводы сформулированы неверно)
- Метод решения задачи реализован неправильно или не подходит для решения поставленной задачи
- Предобработка текста отсутствует без объективного обоснования причин
- Описательная статистика отсутствует