

Разбор сложных заданий контрольной работы

31 октября 2025

Вариант 3 задание 4, Вариант 4 задание 28, Вариант 1 задание 30 (Ответ в лекции 7 - тематическое моделирование)

4

Вопрос:

Какую ключевую особенность вводит модель **Latent Dirichlet Allocation (LDA)**?

Варианты ответов:

- A) Добавляет **априорные распределения Дирихле для тем и слов**, что повышает устойчивость модели
- B) Использует распределение Дирихле только для слов, **игнорируя распределение тем**
- C) Применяет распределение Дирихле для **нормализации матрицы частот слов**
- D) Заменяет вероятностную модель pLSA на **детерминированную**, основанную на распределении Дирихле

(правильный ответ: A)

“Априорная вероятность (prior probability) представляет собой исходную оценку вероятности события до получения новых эмпирических данных.”


LDA

LDA — Latent Dirichlet Allocation (латентное размещение Дирихле)

Вероятностная модель тем

Идея:

Каждый документ — смесь тем, а каждая тема — распределение по словам, но теперь всё это задаётся через вероятностные распределения



LDA

Проблема pLSA: не умеет обрабатывать новые документы —распределение $P(z|d)$ считается отдельно для каждого документа в обучении

Как это решает LDA:

LDA рассматривает $P(z|d)$ не как фиксированный параметр, а как случайную величину, порождённую из распределения Дирихле с параметром α

Аналогично, распределение слов по темам $P(w|z)$ также считается случайным и порождается из Дирихле с параметром β

Распределение Дирихле — это распределение на наборах вероятностей.

Оно позволяет случайно, но управляемо задавать, насколько документ состоит из разных тем (параметр α) и насколько тема состоит из разных слов (параметр β)

- Малое α : документ про 1–2 темы
- Большое α : документ равномерно про всё

LDA

Идея модели

LDA предполагает, что тексты созданы так:

Для каждой темы z задаётся распределение слов ϕ_z

$$\phi_z \sim Dir(\beta)$$

Для каждого документа d задаётся распределение тем θ_d

$$\theta_d \sim Dir(\alpha)$$

Для каждого слова в документе:

$$z_{dn} \sim Mult(\theta_d), \quad w_{dn} \sim Mult(\phi_{z_{dn}})$$

сначала выбираем тему, потом выбираем слово из этой темы

LDA

θ_d показывает, о чём этот документ

Например, 70% «техника», 30% «доставка»

ϕ_z показывает, из каких слов состоит тема

Например, «камера», «экран», «фото»

Модель пытается подобрать такие распределения, чтобы наблюдаемые слова w_{dn} объяснялись наилучшим образом

Вариант 3 задание 9 (Ответ в лекции 7 - тематическое моделирование)

9

Вопрос:

Какую роль играют гиперпараметры α (альфа) и β (бета) в модели LDA (Latent Dirichlet Allocation)?

Варианты ответов:

- A) α управляет скоростью обучения, а β отвечает за регуляризацию модели
- B) α и β используются только при инициализации модели и не влияют на результаты
- C) α регулирует распределение тем в документе, а β — распределение слов в теме
- D) α задаёт количество тем, а β — количество слов в словаре

(правильный ответ: C)

LDA

Параметры Дирихле:

α — смешанность тем в документах

- маленькая α : документ про 1–2 темы
- большая α : документ равномерно про всё

β — сглаженность слов в темах

- маленькая β : темы чёткие, узкие
- большая β : темы пересекаются по словам

$$\theta_d \sim Dir(\alpha), \quad \phi_z \sim Dir(\beta)$$

Вариант 3 задание 15, вариант 1 задание 27, вариант 2 задание 22 (Ответ в лекции 7 - тематическое моделирование)

15

Вопрос:

Какова основная идея метода **LSA (Latent Semantic Analysis)** в обработке текстов?

Варианты ответов:

- A) Снижение размерности **document-term matrix** с помощью **сингулярного разложения** для выявления **скрытых смысловых связей**
- B) Определение **вероятностного распределения слов по темам** с использованием априорных параметров
- C) **Кластеризация слов по частоте встречаемости** без учёта структуры документов
- D) Обучение **нейронной сети** для выделения семантических признаков текста

(правильный ответ: A)

LSA

Latent Semantic Analysis (LSA, Латентно-семантический анализ) — это метод анализа текстовых данных, основанный на линейной алгебре, который выявляет скрытые смысловые (семантические) связи между словами и документами

Он строит векторное представление слов и документов в общем низкоразмерном пространстве, где близость векторов отражает сходство по смыслу, а не только по совпадению слов

LSA

Алгоритм

- Строим Document-term matrix (или TF-IDF)

$$w_{x,y} = \text{tf}_{x,y} \times \log \left(\frac{N}{\text{df}_x} \right)$$

TF-IDF

Term x within document y

$\text{tf}_{x,y}$ = frequency of x in y

df_x = number of documents containing x

N = total number of documents

Документ	Текст
D1	Кошка сидит на окне и смотрит на улицу.
D2	Собака лежит на полу и смотрит на кошку.
D3	Кошка и собака спят вместе на полу.
D4	На окне стоит цветок и кошка смотрит на него.



Документ	кошка	собака	смотрит	окно	пол	улицу	цветок	спят	лежит	стоит
D1	0.41	0.00	0.41	0.41	0.00	0.52	0.00	0.00	0.00	0.00
D2	0.29	0.37	0.29	0.00	0.37	0.00	0.00	0.00	0.37	0.00
D3	0.34	0.34	0.00	0.00	0.34	0.00	0.00	0.49	0.00	0.00
D4	0.33	0.00	0.33	0.33	0.00	0.00	0.43	0.00	0.00	0.33

LSA

Алгоритм


- Далее мы применяем SVD (Singular Value Decomposition, Сингулярное разложение):

$$M = U \Sigma V^T$$

$U \in \mathbb{R}^{N \times N}$ — матрица документов


$V \in \mathbb{R}^{M \times M}$ — матрица слов

$\Sigma \in \mathbb{R}^{N \times M}$ — диагональная матрица сингулярных чисел



LSA

$$M = U \Sigma V^T$$



LSA

Мы оставляем только первые k крупнейших сингулярных значений

Тогда в матрице $\sum_k V_k^T$ каждый столбец — это вектор документа в скрытом пространстве тем

	d1	d2	d3	d4	d5	d6
t1	0.57	1.71	0.57	0	0	0
t2	0	0	0	0.68	0.68	1.36

 $=$

	t1	t2
t1	1.9	0
t2	0	1.7

 $\times$

	d1	d2	d3	d4	d5	d6
t1	0.3	0.9	0.3	0	0	0
t2	0	0	0	0.4	0.4	0.8

pLSA

После LSA (который основан на SVD) стало понятно, что мы умеем находить скрытые темы в текстах, но SVD — чисто линейная алгебра, без вероятностного смысла.

Хочется, чтобы модель умела говорить: «эта тема встречается с вероятностью 0.3», это слово в этой теме встречается с вероятностью 0.1», и т.д. То есть превратить линейные оси из LSA в реальные вероятностные распределения

Probabilistic Latent Semantic Analysis (pLSA) — это вероятностная версия LSA. Она описывает, как слово появляется в документе через скрытые темы.

Вариант 4 задание 9, вариант 1 задание 2 (Ответ в Лекции 3 - векторизация на основе эмбедингов)

9

Вопрос:

Какие две основные архитектуры используются в модели **Word2Vec**?

Варианты ответов:

- A) CBOW и Skip-gram
- B) BoW и TF-IDF
- C) Encoder и Decoder
- D) LSTM и GRU

(правильный ответ: **A**)

Word2Vec


Word2Vec — это метод обучения векторных представлений слов (эмбеддингов), предложенный Google в 2013 году

Основная концепция


- Слова, встречающиеся в схожих контекстах, имеют близкий смысл
- Задача: обучить вектора так, чтобы они отражали статистику контекстов
- Word2Vec преобразует дискретные слова в плотные векторы (эмбеддинги)

Виды архитектур Word2Vec

CBOW




Skip-gram



Word2Vec


Нейросеть учит такие векторы слов, чтобы скалярное произведение между векторами двух слов, которые часто используются в одном контексте, были как можно больше



SkipGram и CBOW

SkipGram — предсказание слов контекста по центральному слову

Студент МИИТ **вышел** на станции метро «Менделеевская»



SkipGram и CBOW

CBOW (Continuous Bag Of Words) — предсказание центрального слова по словам контекста

Студент МИИТ **вышел** на станции метро «Менделеевская»



Вариант 4 задание 16, вариант 3 задание 25, вариант 2 задание 10 (Ответ в Лекции 3 - векторизация на основе эмбеддингов)

16

Вопрос:

Какую ключевую особенность вводит **FastText** по сравнению с базовой моделью **Word2Vec**?

Варианты ответов:

- A) Использует только частоту слов без контекста
- B) Применяет взвешивание TF-IDF перед обучением
- C) Учитывает длину слов и порядок их появления в предложении
- D) Учитывает символьные N-граммы, что позволяет кодировать даже незнакомые слова

(правильный ответ: **D**)

FastText

У алгоритма word2vec есть недостаток: если в новых текстах встречаются слова, отсутствующие в обучающей выборке, их не получится закодировать при помощи word2vec

FastText — это модификация word2vec, которая решает эту проблему при помощи использования символьных N-грамм. То есть в качестве токенов используются не только слова, но и их кусочки, N-граммы



Основная концепция FastText

- Разработан Facebook AI (2016) как улучшение Word2Vec
- Представление слова = сумма векторов его символьных n-грамм
- Вектор слова = эмбединг слова + эмбединги всех его морфем и частей

Преимущества:

- Можно получить эмбединг даже для слова, которого не было в обучающем корпусе

Например: «машинка» разбивается на знакомые куски «машин-» и «-ка»

- Хорошо работает с агглютинативными и морфологически сложными языками:

русский: «работа», «работать», «работающий»

турецкий, финский, венгерский

Вариант 4 задание 31 (Ответ в Лекции 3 - эмбединги)

31

Задание:

Даны два вектора слов:

$$\mathbf{A} = [1, 0]$$

$$\mathbf{B} = [0, 1]$$

Вычислите **косинусное сходство** между ним

Правильный ответ: 0

$$\cos(\theta) = \frac{\mathbf{A} \cdot \mathbf{B}}{\|\mathbf{A}\| \cdot \|\mathbf{B}\|}$$

$$\text{similarity} = \cos(\theta) = \frac{\mathbf{A} \cdot \mathbf{B}}{\|\mathbf{A}\| \|\mathbf{B}\|} = \frac{\sum_{i=1}^n A_i B_i}{\sqrt{\sum_{i=1}^n A_i^2} \sqrt{\sum_{i=1}^n B_i^2}}$$

$$\cos(\theta) = \frac{\mathbf{A} \cdot \mathbf{B}}{\|\mathbf{A}\| \cdot \|\mathbf{B}\|} = \frac{1 \times 0 + 0 \times 1}{1 \times 1} = 0$$

Градиентный спуск

Дана функция: $f(x, y)$

Тогда градиент функции: $\nabla f = \left\{ \frac{\partial f}{\partial x}, \frac{\partial f}{\partial y} \right\}$

Градиент функции — вектор, состоящий из частных производных функции по всем её аргументам

Найдем градиент функции $f(x, y, z) = 2x - y^2 + yz$

в точке $(x, y, z) = (1, 1, 1)$

Вариант 1 задание 33 (Лекция 4 - градиентный спуск)

33

Задание:

Найдите градиент функции $f(x, y, z) = x^2y - 3yz + 4x$

в точке $(x, y, z) = (1, 2, -1)$

Формула градиента:

$$\nabla f = \left(\frac{\partial f}{\partial x}, \frac{\partial f}{\partial y}, \frac{\partial f}{\partial z} \right)$$

Правильный ответ:

$$\nabla f(1, 2, -1) = \{8, 4, -6\}$$

$$\frac{\partial f}{\partial x} = 2xy + 4 \Rightarrow 2(1)(2) + 4 = 8$$

$$\frac{\partial f}{\partial y} = x^2 - 3z \Rightarrow 1^2 - 3(-1) = 4$$

$$\frac{\partial f}{\partial z} = -3y \Rightarrow -3(2) = -6$$

“Градиент функции — это вектор, состоящий из всех её частных производных. Он указывает направление наискорейшего роста функции.” (“дифференцируем по одной переменной, считая остальные константами”)

Вариант 4 задание 33

33

Задание:

Найдите градиент функции $f(x, y, z) = e^x y - 2xz + z^2$

в точке $(x, y, z) = (0, 3, 2)$

Правильный ответ: $\nabla f(0, 3, 2) = \{-1, 1, 4\}$

$$\frac{\partial f}{\partial x} = e^x y - 2z \Rightarrow e^0(3) - 2(2) = -1$$

$$\frac{\partial f}{\partial y} = e^x \Rightarrow e^0 = 1$$

$$\frac{\partial f}{\partial z} = -2x + 2z \Rightarrow -2(0) + 2(2) = 4$$

Вариант 4 задание 11, вариант 1 задание 19, вариант 3 задание 30 (Ответ в лекции 5 - нейронные сети)

11

Вопрос:

Какова основная идея метода **Dropout** при обучении нейронных сетей?

Варианты ответов:



- A) Временно отключать случайные нейроны во время обучения, чтобы снизить переобучение
- B) Увеличивать количество нейронов в скрытых слоях при каждом шаге
- C) Искусственно добавлять шум в данные для ускорения сходимости
- D) Удалять наименее важные признаки из обучающего набора

(правильный ответ: A)

Dropout

Dropout — это метод регуляризации, используемый в нейронных сетях для снижения риска переобучения.

Его суть заключается в том, что во время обучения часть нейронов случайным образом временно отключается: их выходные значения принудительно приравниваются к нулю. Такое исключение выполняется независимо для каждого нейрона и на каждой итерации, благодаря чему сеть не привыкает полагаться на конкретные связи и учится строить более устойчивые представления



Вариант 2 задание 17, вариант 1 задание 20, вариант 4 задание 3 (Ответ в лекции 8 - распознавание именованных сущностей)

17

Вопрос:

Какую задачу решает модель **Conditional Random Fields (CRF)** в контексте обработки текста?

Варианты ответов:

- A) Генерирует новые тексты на основе вероятностной модели
- B) Предсказывает последовательности меток, учитывая зависимости между соседними токенами
- C) Определяет наиболее частые слова в корпусе
- D) Классифицирует тексты по заранее заданным темам

(правильный ответ: B)

Постановка задачи

Задача NER

На вход подаётся предложение — последовательность слов (токенов):

$$x = [x_1, x_2, \dots, x_n]$$

На выходе — такая же последовательность меток:

$$y = [y_1, y_2, \dots, y_n]$$

Каждая метка указывает, к какой категории относится слово (или вне сущности)

Пример:

x = ["Компания", "Яндекс", "была", "основана", "в", "1997", "году", "в", "Москве"]

y = ["O", "B-ORG", "O", "O", "O", "B-DATE", "I-DATE", "O", "B-GPE"]

Conditional Random Fields

Conditional Random Fields (CRF, Условное случайное поле) — это дискриминативная вероятностная модель, определяющая распределение вероятностей меток $y=[y_1, y_2, \dots, y_n]$ при известных наблюдениях $x=[x_1, x_2, \dots, x_n]$

$$P(y|x) = \frac{1}{Z(x)} \exp \left(\sum_{i=1}^n \sum_j w_j f_j(y_i, y_{i-1}, x, i) \right)$$

CRF моделирует условное распределение меток, не делая предположений о том, как данные порождаются. Модель учится напрямую, какие метки наиболее вероятны для данной последовательности наблюдений, учитывая все признаки слов и связи между соседними метками

Вариант 4 задание 20 (Ответ в лекции 4 - функции активации)

20

Вопрос:


Какое основное преимущество функции активации **ReLU** по сравнению с сигмойдой?

Варианты ответов:

- A) Она возвращает значения только от -1 до 1
- B) Она вычисляется быстрее и помогает избежать проблемы затухающего градиента
- C) Она делает сеть симметричной относительно нуля
- D) Она всегда активирует все нейроны, даже при отрицательных входах

(правильный ответ: **B**)

Различные функции активации. Сигмоида




$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

Сигмоидная функция хорошо подходит в качестве активации на выходном слое нейросети для задач бинарной классификации, так как вместе с правильной функцией потерь (log-loss) она позволяет интерпретировать выход как вероятность принадлежности к классу.

Однако у неё есть недостаток, из-за которого её редко используют в скрытых слоях: при больших по модулю значениях аргумента $|x|$ функция $\sigma(x)$ изменяется очень слабо, а её производная $\sigma'(x)$ становится близкой к нулю. Это приводит к тому, что градиент функции потерь $\nabla Q(w)$ почти обнуляется, и обучение, основанное на градиентном спуске, может «замереть»

Различные функции активации. ReLU



$$ReLU(x) = \max(0, x)$$

ReLU (Rectified Linear Unit) — это простая и популярная функция активации в глубоком обучении, которая преобразует входные значения в диапазон от 0 до $+\infty$: если вход меньше или равен нулю, результат равен нулю, а если больше нуля — возвращается само значение. Графически это линейная функция с обнулением в точке 0. ReLU вычисляется быстрее сигмоиды, так как не требует сложных операций, и помогает справиться с проблемой затухающего градиента при обучении.

В то же время у неё есть ограничения: некоторые нейроны могут "умирать", оставаясь навсегда неактивными при отрицательных входах, а также функция несимметрична относительно нуля, что может вызывать смещение активаций в положительную область. Для уменьшения этих эффектов применяют модификации вроде Leaky ReLU или ELU

Вариант 4 задание 26, вариант 1 задание 16, вариант 2 задание 25, вариант 3 задание 1 (Ответ в лекции 4 - функции активации)

26

Вопрос:


Чем гиперболический тангенс ($\tanh$) отличается от сигмоидальной функции при использовании в нейронных сетях?

Варианты ответов:

- A) Возвращает значения только от 0 до 1
- B) Не имеет производной, поэтому не применяется в градиентных методах
- C) Преобразует данные в диапазон от -1 до 1 и имеет более плавный переход
- D) Используется только для нормализации входных данных

(правильный ответ: C)

Различные функции активации. Гиперболический тангенс



$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$$

Гиперболический тангенс по своей сути похож на сигмоидальную функцию и также применяется в нейронных сетях. Он преобразует входные данные в значения от -1 до 1 , что делает его удобным, например, для задач регрессии: результаты, близкие к -1 , трактуются как отрицательные, близкие к 1 — как положительные, а около нуля — как нейтральные.

В отличие от сигмоиды, тангенс обладает более плавным переходом, что помогает сети эффективнее выявлять сложные зависимости в данных. Кроме того, его производная является непрерывной и гладкой, что делает возможным применение оптимизационных методов, основанных на градиенте

Вариант 4 задание 30, вариант 1 задание 9 (Ответ в лекции 4 - функции активации)

30

Вопрос:


Для чего используется функция активации **Softmax** в нейронных сетях?

Варианты ответов:


- A) Для уменьшения переобучения за счёт **обнуления отрицательных значений**
- B) Для преобразования выходов сети в **вероятностное распределение по классам**
- C) Для **ускорения обучения** за счёт упрощения вычислений
- D) Для **выделения самого большого значения среди выходов** модели

(правильный ответ: **B**)

Различные функции активации. Softmax



$$\text{Softmax}(z_i) = \frac{e^{z_i}}{\sum_{j=1}^K e^{z_j}}, \quad i = 1, 2, \dots, K \quad K \text{ — количество классов}$$



Softmax — это функция активации, которая преобразует набор чисел в вероятностное распределение по классам. Для каждого значения она вычисляет экспоненту и нормирует её на сумму экспонент всех элементов, в результате чего выходные значения лежат в диапазоне от 0 до 1 и в сумме дают 1. Благодаря этому Softmax часто используют на выходном слое нейронных сетей для многоклассовой классификации, где каждый результат интерпретируется как вероятность принадлежности объекта к соответствующему классу

Вариант 4 задание 23, вариант 1 задание 29 (Ответ в лекции 3 - языковые модели)

23

Вопрос:

Что отражает марковское свойство в цепях Маркова?

Варианты ответов:

- A) Будущее состояние зависит от всех предыдущих состояний процесса
- B) Будущее состояние не зависит от прошлого вообще
- C) Будущее состояние зависит только от текущего состояния, а не от всей истории
- D) Все состояния в цепи выбираются случайно и независимо

(правильный ответ: C)

Цепи Маркова

Цепь Маркова — это случайный процесс, в котором будущее состояние зависит только от текущего, а не от всей прошлой истории

Марковское свойство:

$$P(X_{t+1} \mid X_t, X_{t-1}, \dots, X_0) = P(X_{t+1} \mid X_t)$$

Вариант 1 задание 34

34

Задание:

Найти значение выхода нейрона с тремя входами

Входные значения: $x_1 = 2, x_2 = -1, x_3 = 3$


Веса:

$$w_1 = 0.5, w_2 = -0.4, w_3 = 0.8$$

Смещение (bias): $b = 0.2$

Функция активации $f(z) = \text{ReLU}(z) = \max(0, z)$

Правильный ответ: 4.0



$$z = 0.5 \cdot 2 + (-0.4) \cdot (-1) + 0.8 \cdot 3 + 0.2 = 1.0 + 0.4 + 2.4 + 0.2 = 4.0$$

$$y = \text{ReLU}(4.0) = 4.0$$

Структура нейрона

x_1, x_2, x_n – входы в нейрон


w_1, w_2, w_n – веса нейрона

Σ – сумматор

$f(x)$ – функция активации

y – выход нейрона

b – смещение



$$f(x_1w_1 + x_2w_2 + \dots + x_nw_n + b) = f\left(\sum_{i=1}^n x_iw_i + b\right)$$